Домашнее задание 1. Визуализация данных и описательная статистика. 21 апреля полночь.

Введение

Это задание предназначено не только для проверки ваших вычислительных навыков, но и для оценки вашей способности критически подходить к представлению и интерпретации данных. Необходимо показать всю работу и подробно объяснить свои рассуждения.

Домашнее задание выполняется **самостоятельно**.

Крайний срок сдачи 21 апреля полночь (ночь с 20 по 21 апреля).

Требования к оформлению

1. **Один файл в формате PDF:** Объедините код и отчет в одном PDF-документе.
2. **Формулировка задания:** Формулировка задания (как показано ниже) должна быть включена в ваш PDF-файл, чтобы преподаватель мог легко сориентироваться в вашей работе.
3. **Код:**
    - Все выполненные на компьютере работы (например, код в R, скрипты) должны быть включены в блоки кода.
    - Четко обозначьте каждый раздел кода комментариями, объясняющими смысл кода.
4. **Рукописные работы:**
    - Каждое упражнение, выполненное от руки (Упражнение 1), должно быть отсканировано и вставлено в PDF-файл.
    - Убедитесь, что все отсканированные страницы выглядят четко и разборчиво.
    - Обратите внимание на название файла, что вы выкладываете в смарт лмс (см. критерии оценки).

Система подсчета баллов за ДЗ1

Максимальная оценка: 6 баллов **Минимальная оценка:** 0 баллов

Важное замечание: Если хотя бы одно упражнение (или часть упражнения) у двух студентов окажется одинаковым, оба студента получат 0 баллов за всю домашнюю работу. Это правило особенно относится к упражнению 3.

Критерии	**Штраф (баллы)**	**Комментарии**
1. Одно упражнение (или часть упражнения), выполнено с ошибками или отсутствует	-1	За каждое неполное, неправильное или нечетко задокументированное задание в упражнении снимается 1 балл.
2. Ошибка в нумерации страниц и/или отсутствие ФИО студента, кто его выполнял	-1	Документ должен иметь правильную нумерацию страниц. ФИО должно быть указано на титульной странице.
3. Название файла `"номер_группы_ДЗ1_Имя_Фамилия''`	-3	Файл должен быть назван именно так, как это предусмотрено в этом пункте. Вы ставите номер вашей учебной группы (а не текст "номер группы")
4. Представление нескольких файлов	Автоматически 0	Все задания должны быть объединены в один PDF-документ.
5. Несвоевременная сдача (после дедлайна)	Автоматически 0	Материалы, полученные после установленного срока, будут оцениваться в 0 баллов.

1 Упражнения

Упражнение 1

Обратите внимание: Это задание должно быть выполнено **письменно от руки** и в отсканированном варианте добавлено в отчет.

Имеется следующий набор данных:

$$19,\ 24,\ 28,\ 32,\ 32,\ 37,\ 39,\ 44,\ 48,\ 113,\ 15,\ 1$$

Задание:

1. Вычислите **среднее**, **медиану**, и **моду** (если это возможно).

2. Для медианы поясните, как вы определяете ее для набора данных с четным количеством значений.

3. Вычислите **размах** и **межквартильный размах (IQR)**. Объясните, как вы определяете первый квартиль (Q_1) и третий квартиль (Q_3).

4. Рассчитайте **дисперсию** и **стандартное отклонение** вручную, используя предложенные формулы. Покажите каждый шаг вашего расчета.

5. Вкратце расскажите, почему каждая мера (центральной тенденции и разброса) важна. Объясните, в каких случаях каждая из них будет наиболее информативна.

Упражнение 2

Набор данных 1: Результаты математической олимпиады

Следующие баллы (из 100) получили 30 участников:

45, 78, 92, 65, 88, 71, 56, 81, 74, 90, 65, 52, 45, 83, 91, 77, 63, 71, 88,

90, 49, 78, 60, 72, 85, 45, 91, 80, 74, 56

Набор данных 2: Ежедневное количество учебных часов

Количество часов, которые 10 студентов учатся ежедневно, составляет:

2, 3, 2.5, 3.5, 2, 4, 3, 2.5, 3, 3

Затем добавьте к этому набору данных экстремальное значение (15 часов), чтобы изучить влияние выбросов.

Задания:

Точечный график и гистограмма

1. Используя R, создайте точечную диаграмму для набора данных 1, чтобы представить распределение баллов в олимпиаде.

2. Опишите все видимые кластеры, пробелы или повторяющиеся значения. Обсудите, почему точечная диаграмма является эффективным инструментом для первоначального предварительного анализа данных.

3. Постройте четыре гистограммы для набора данных 1 в R, используя различную ширину столбцов (например, 5, 10, 15 и 20).

4. Объясните, как вы определяете подходящую ширину столбца.

5. Объясните, как изменение ширины столбца влияет на форму и интерпретацию гистограммы. Каковы последствия выбора очень узкой и очень широкой ширины столбца?

Анализ боксплотов и эффекты выбросов

6. Создайте боксплот для набора данных 1 с помощью R.

7. Пометьте на боксплоте минимум, первый квартиль (Q1), медиану, третий квартиль (Q3) и максимум. Четко обозначьте все выбросы.

8. Для набора данных 2 (ежедневные часы учебы) создайте в R две диаграммы: одну для исходных данных, а другую - после добавления экстремального наблюдения (15 часов).

9. Сравните эти два графика и обсудите, как изменились медиана и межквартильный размах (IQR) после добавления экстремального значения.

10. Объясните, какая мера центральной тенденции (среднее или медиана) более устойчива к выбросам, используя в качестве доказательства ваши графики.

Сравнительная визуализация нескольких наборов данных

11. Создайте смоделированный набор данных, представляющий результаты соревнований второго класса. Убедитесь, что этот набор данных отличается по мере центральной тенденции и изменчивости от набора данных 1.

12. Сгенерируйте боксплоты в R, расположите их рядом друг с другом, сгенерируйте наложенные гистограммы в R для обоих наборов данных. Используйте разные цвета и четкие легенды, чтобы облегчить сравнение.

13. Напишите небольшой параграф (150-200 слов), в котором сравните две данные группы. Обратите внимание на различия в мерах центральной тенденции, разброса, скоса и наличия заметных выбросов.

14. Укажите, какой метод визуализации показался вам наиболее эффективным для сравнения, и обоснуйте свой выбор.

Упражнение 3. "Ловушки"презентации

1. **Выберите актуальный сюжет:**
   Выберите текущее событие или ситуацию, которая привлекла значительное внимание СМИ. Дайте краткое описание сюжета и укажите соответствующий контекст.

2. **Сбор данных и визуализация:**
   Найдите хотя бы одну визуализацию данных (диаграмму, график или инфографику), связанную с выбранным вами сюжетом. Это может быть скриншот, изображение из онлайн-источника или опубликованный отчет. Укажите соответствующие цитаты или ссылки на источники.

3. **Идентифицировать "ловушки"презентации:**
   Проанализируйте выбранную визуализацию и перечислите варианты дизайна, которые могут намеренно ввести зрителя в заблуждение. Рассмотрите такие аспекты, как:

   - Усеченные или манипулируемые оси
   - Неправильное масштабирование или ширина столбцов

- Избирательная выборка данных или преднамеренное упущение данных
- Вводящие в заблуждение обозначения или отсутствие контекста
- Введение в заблуждение с помощью цветов или графических элементов

4. **Критический анализ:**
   Напишите подробное объяснение (примерно 300-500 слов), касающееся:
   - Как выявленные «ловушки» в презентации искажают интерпретацию данных.
   - Потенциальные цели, стоящие за намеренным искажением данных.
   - Влияние этих искажений на общественное мнение или принятие решений.
5. **Предложить улучшенную визуализацию:**
   Предложите альтернативный метод представления тех же данных, который обеспечит более честное и ясное представление. Ваше предложение должно включать:
   - Описание или эскиз улучшенной визуализации.
   - Объяснения ваших решений относительно масштабирования, дизайна осей, обозначений и выбора данных.
6. **Выводы:**
   В заключение напишите краткое резюме (150-200 слов) о важности соблюдения этических норм визуализации данных и о том, как вводящие в заблуждение представления могут подорвать доверие общества.