Домашнее задание 3: Доверительные интервалы и проверка гипотез (на основе данных RLMS-HSE и собственных опросов). 2 июня полночь.

Преподаватель: Татьяна Журавлёва

2025

Общие положения

Студенты работают в группах по 5-7 человек.

Все участники получают одинаковый балл, независимо от вклада каждого. Это отражает реальный рабочий процесс: в жизни вам всегда придется работать в команде, где важен коллективный результат, а не индивидуальные усилия.

Группы должны выполнить **ВСЕ 4 задания**, подготовить отчет и презентацию по каждому.

На семинаре случайным образом выбирается одна группа и одно из четырех заданий, которое они должны защитить у доски. Поэтому готовить нужно **ВСЁ**.

Крайний срок сдачи 2 июня полночь.

Требования к оформлению

1. **Один файл в формате PDF:** Объедините код и отчет в одном PDF-документе.
2. **Формулировка задания:** Формулировка задания (как показано ниже) должна быть включена в ваш PDF-файл, чтобы преподаватель мог легко сориентироваться в вашей работе.
3. **Код:**
   - Все выполненные на компьютере работы (например, код в R, скрипты) должны быть включены в блоки кода.
   - Четко обозначьте каждый раздел кода комментариями, объясняющими смысл кода.

Система подсчета баллов

Максимальная оценка: 9 баллов **Минимальная оценка:** 0 баллов

Важное замечание: Если хотя бы одно задание (или часть задания) у двух групп студентов окажется идентичным, обе группы студентов получат 0 баллов за всю домашнюю работу.

Критерии	**Штраф (баллы)**	**Комментарии**
1. Одно задание (или часть задания), выполнено с ошибками или отсутствует	-1 за задание	За каждое неполное, неправильное или нечетко задокументированное задание или его часть снимается 1 балл.
2. Ошибка в нумерации страниц и/или отсутствие ФИО студентов, кто его выполнял	-1	Документ должен иметь правильную нумерацию страниц. Все ФИО должны быть указаны на титульной странице.
3. Название файла *"номер_группы_ДЗ_3_Имя_Фамилия"*	Автоматически 0	Файл должен быть назван именно так, как это предусмотрено в этом пункте.
4. Представление нескольких файлов	Автоматически 0	Все задания должны быть объединены в один PDF-документ.
5. Несвоевременная сдача (после дедлайна)	Автоматически 0	Материалы, полученные после установленного срока, будут оцениваться в 0 баллов.
6. Плохая презентация на семинаре (некомпетентность, неподготовленность)	-2 балла	Даже если отчет идеален, но презентация провалена, теряеются 2 балла.

Советы по успешному выполнению

- **Делите обязанности**: кто-то ищет исследования, кто-то пишет отчет, кто-то делает слайды.
- **Проверяйте работы друг друга** и обсуждайте **ВСЕ** задания друг с другом: если кто-то не справился, команда несет общую ответственность.
- **Репетируйте защиту**: неожиданный вопрос на семинаре может стоить вам 2 балла.
- **Делайте презентации яркими и краткими**: слушатели должны понять суть за 5 минут.

Формат презентации

Презентация (по каждому заданию)

- 5-6 слайдов.
- Время на защиту 5-7 минут.
- Минимум текста, максимум визуализации.

Как будет проходить защита?

- На семинаре преподаватель случайным образом выбирает одну группу.
- Случайным образом выбирается одно из четырех заданий, которое группа должна защищать.
- Проходит защита 2-3 заданий из четырех, в зависимости от времени.
- Один представитель группы (выбираемый преподавателем) выходит к доске и:
  - Кратко рассказывает о задании с помощью слайдов.
  - Отвечает на вопросы аудитории и преподавателя.
- Если представитель группы плохо отвечает, теряется до 2 баллов, даже если отчет идеален.

Задание 1. Разрыв в доходах между мужчинами и женщинами

Пошаговая инструкция

1. **Загрузка и подготовка данных.** Перейдите на официальный сайт RLMS-HSE https://www.hse.ru/rlms и скачайте данные за интересующий вас год.
2. **Выбор подмножества данных:**
   - Выберите один конкретный год (например, 2021).
   - Выберите один город (например, Москва, Екатеринбург и т.д.) или работайте по всей стране.
   - Выберите одну отрасль (например, образование, медицина, промышленность). Найдите переменную в данных RLMS-HSE, отвечающую за отрасль.
   - Найдите переменную, отражающую зарплату.
   - Сохраните нужные вам данные в R.
3. **Построение доверительных интервалов.**

- Постройте два отдельных доверительных интервала для средней зарплаты мужчин и женщин в выбранном вами году, городе и отрасли.
- Постройте доверительные интервалы для разных уровней значимости (например, 90%, 95%, 99%).
- Интерпретация. Объясните, что означают построенные интервалы в контексте социальной политики, рынка труда, равенства и т.д.

4. **Проверка гипотезы о равенстве средних зарплат у мужчин и женщин.** Проведите полный 5-этапный анализ, как обсуждалось на лекции:

   1. Формулировка гипотез:

   $$H_0 : \mu_{\text{муж}} = \mu_{\text{жен}} \quad \text{vs.} \quad H_1 : \mu_{\text{муж}} \neq \mu_{\text{жен}}$$

   2. Выбор тестовой статистики и её распределения. Объясните какую статистику вы выбираете и посчитайте ее значение.
   3. Критическая область или p-value: выберите уровень значимости α (например, 0,05), найдите критическое значение или рассчитайте p-value. Сделайте это для разных уровней значимости.
   4. Статистическое решение: сравните значение тестовой статистики с критическим значением / p-value с α. Примите решение.
   5. Интерпретация: объясните, что результат теста означает для реального мира. Что можно утверждать о различиях в зарплате?
   6. Проведите точно такой же пятиэтапный анализ, когда альтернативная гипотеза $H_1 : \mu_{\text{муж}} > \mu_{\text{жен}}$

Задание 2. Интернет среди пожилых

Пошаговая инструкция

1. **Сбор собственных данных.** Проведите мини-опрос среди людей старше 60 лет (например, ваших родственников, знакомых, соседей, в соцсетях и т.д.). Используйте простую Яндекс-форму или бумажный опросник. Запишите их возраст, пол и ответ на главный вопрос: *«Пользуетесь ли вы интернетом?»* (да/нет)

2. **Определение минимального объёма выборки:**

   - Проведите анализ мощности (power analysis) для определения необходимого количества респондентов.
   - Используйте, например, функцию ‘power.prop.test‘ в R. Укажите желаемую мощность теста 0.9.
   - Вам будет необходима предполагаемая альтернативная доля (например, 0.4 или 0.6 или другая), не берите ее с потолка, используйте научную литературу, найдите статью, изучающую этот вопрос, возьмите альтернативную долю из нее.

3. **Перенесите даные в R**. Сделайте анализ средних всех трех собранных переменных.

4. **Построение доверительного интервала для доли.**

   - Рассчитайте долю пользователей интернета в вашей выборке ($\hat{p}$).
   - Постройте доверительный интервал для этой доли при различных уровнях значимости (90%, 95%, 99%).
   - Интерпретируйте: что говорит интервал? Насколько уверенно можно утверждать, что большинство/меньшинство пожилых людей пользуются интернетом?

5. **Проверка гипотезы.** Проверьте гипотезу о том, что менее половины пожилых людей пользуются интернетом:

   1. Формулировка гипотезы:

   $$H_0 : \pi = 0{,}5 \quad \text{vs.} \quad H_1 : \pi < 0{,}5$$

   2. Выбор и расчет тестовой статистики.
   3. Критическая область или p-value: выберите $\alpha = 0{,}05$ и/или $\alpha = 0{,}01$, найдите критическое значение или рассчитайте p-value.
   4. Статистическое решение: делаем вывод о том, можно ли отвергнуть гипотезу о том, что половина пожилых пользуется интернетом.
   5. Интерпретация: объясните, какие социальные выводы можно сделать. Какие факторы могут влиять? Стоит ли предпринимать меры для повышения цифровой грамотности?

Задание 3. Семья и работа

Тема: Влияет ли семейный статус на вероятность трудоустройства?

Пошаговая инструкция

1. **Загрузка и подготовка данных.** Загрузите RLMS-HSE с сайта https://www.hse.ru/rlms. Выберите один конкретный год (отличающийся от выбранного в задании 1).

2. **Фильтрация данных:**

   - Возраст: выберите только людей от 25 до 45 лет.
   - Переменная занятости: выберите переменную, отражающую, работает ли человек (например, по статусу занятости).
   - Переменная семейного положения: выделите две группы:
     - Женатые/замужние (официально зарегистрированный брак);
     - Неженатые/незамужние (включая вдовых, разведённых, никогда не состоявших в браке).

- Перенесите все данные в R (четыре переменные: пол; возраст; переменная, отражающая наличие работы, переменная, отражающая семейный статус).

3. **Расчёт долей:**
   - Рассчитайте долю трудоустроенных среди женатых/замужних $\hat{p}_1$;
   - Рассчитайте долю трудоустроенных среди неженатых/незамужних $\hat{p}_2$.
4. **Построение доверительного интервала для разности долей:**
   - Постройте доверительный интервал для разности долей трудоустроенных между женатыми/замужними и нет для уровней значимости 90%, 95% и 99%.
   - Интерпретируйте результат: каков возможный разрыв между группами?
5. **Проверка гипотезы о равенстве долей.** Выполните анализ по всем 5 этапам:
   1. Формулировка гипотез:
   $$H_0 : \pi_{\text{в браке}} = \pi_{\text{не в браке}} \quad \text{vs.} \quad H_1 : \pi_{\text{в браке}} \neq \pi_{\text{не в браке}}$$
   2. Выбор и расчет тестовой статистики:
   3. Критическая область или p-value: выберите уровни значимости $\alpha = 0{,}10$, 0,05, 0,01.
   4. Примите решение о принятии/отклонении нулевой гипотезы.
   5. Интерпретация: сделайте вывод, влияет ли семейный статус на занятость. Что это может означать с социальной точки зрения?
6. **Сравнение по полу.** Повторите весь анализ отдельно для мужчин и для женщин:
   - Разделите выборку на мужчин и женщин.
   - Для каждой подгруппы (мужчины, женщины) повторите всю работу по п.5, т.е. проверьте гипотезу о равенстве долей трудоустроенных между женатыми и неженатыми мужчинами, замужними и незамужними женщинами.
   - Сравните результаты: различаются ли эффекты для мужчин и женщин?
   - Обсудите возможные причины различий: экономические, культурные, гендерные роли, ожидания со стороны работодателей и семьи.

Задание 4. До и после: здоровье и пандемия

Исследовательский вопрос: Изменилась ли самооценка здоровья (или другое состояние) после пандемии COVID-19?

Пошаговая инструкция

1. **Выбор показателя.** Выберите одну переменную из RLMS-HSE, связанную со здоровьем, стрессом, настроением, уровнем энергии, частотой обращений к врачу и пр. (например, самооценка состояния здоровья, депрессия, беспокойство, хронические болезни и т.д.). В RLMS-HSE масса вопросов о здоровье. Выберите то, что интересно именно вам.

2. **Выбор волн RLMS.**

   - Найдите одну волну до пандемии (например, 2017 год) и одну волну после пандемии (например, 2021 или 2022).
   - Выберите только тех людей, которые участвовали в обеих волнах (панельные наблюдения).
   - Перенесите все данные в R: пол, возраст, выбранный показатель здоровья.

3. **Создание переменной разности.**

   - Для каждого индивида рассчитайте разность значений выбранного показателя: $d_i = x_{i,\text{после}} - x_{i,\text{до}}$.
   - Это превратит вашу задачу в анализ зависимых (paired) выборок.

4. **Построение доверительного интервала.**

   - Постройте доверительный интервал для среднего изменения μ_d для уровней значимости 90%, 95%, 99%.
   - Интерпретируйте результат: ухудшилось ли в среднем состояние по этому показателю после пандемии?

5. **Проверка гипотезы о средних изменениях здоровья по выбранному показателю.** Проведите полный 5-этапный анализ:

   1. Формулировка гипотез:

      $$H_0 : \mu_d = 0 \quad \text{vs.} \quad H_1 : \mu_d \neq 0$$

   2. Выбор и расчет тестовой статистики.
   3. Для уровней значимости $\alpha = 0{,}10,\ 0{,}05,\ 0{,}01$ рассчитайте критическое значение.
   4. Сравните значение тестовой статистики с критическим значением. Примите решение: отклоняется ли нулевая гипотеза (для каждого уровня значимости)?
   5. Проинтерпретируйте полученный результат.

6. Повторите анализ п.5. отдельно для мужчин и женщин, или по возрастным группам (на ваш выбор):

   - Например: молодые (18–35), средний возраст (36–60), пожилые (60+).
   - Сравните, кто сильнее испытал негативные изменения.

- Обсудите возможные причины: работа на удалёнке, страх за здоровье, изоляция и т.д.

7. Визуализируйте распределение изменений (гистограмма, boxplot), добавьте комментарии.

Удачи и исследовательского азарта!